

The background features a light gray field with blue and dark blue geometric shapes at the corners. On the left, there are several horizontal lines of varying lengths, each ending in a small circle, resembling a circuit board. Similar lines are on the right side.

MUHAMMAD FARHAN SHIDDIQ

ASSIGNMENT – ETL DABI – 20

The background features a light gray field with blue and dark blue geometric shapes at the corners. On the left and right sides, there are circuit-like line drawings with small circles at their ends.

ETL

EXTRACT, TRANSFORM, LOAD

ETL

(EXTRACT, TRANSFORM, LOAD)

ETL adalah proses yang digunakan untuk menggabungkan data dari berbagai sumber ke dalam repositori pusat yang besar yang disebut **gudang data**.

Proses ini melibatkan tiga langkah utama: **ekstraksi** data dari sumber, **transformasi** data agar sesuai untuk analisis, dan **pemindahan** data ke dalam gudang data.



Mengapa ETL itu penting?



Mengintegrasikan Data



Meningkatkan Kualitas Data



Meningkatkan Keputusan Bisnis



Meningkatkan Keadaan dan Efisiensi

Bagaimana proses ETL terjadi ?

Extract

Proses pengambilan data dari sumber data (CSV, Database, API)

Transform

Proses mengubah data agar siap dianalisis.

Load

Proses penyimpanan data yang sudah siap untuk dianalisis.



Extract



Extract adalah proses mengambil data dari sumber (source) ke dalam sistem data warehouse untuk diproses lebih lanjut.

Transform

Cleaning Data (Staging)

- Menghapus Null
- Memastikan type data sudah benar



Modeling (Schema)

Memisahkan data menjadi 2 jenis tabel:

- **Fact Table** -> Data transaksi (angka)
- **Dimension table** -> Deskripsi (produk, toko, customer)



Load (Datamart)

Data yang telah ditransformasikan dimuat ke dalam datamart dalam bentuk table agregasi untuk memudahkan analisis bisnis

Load



Load adalah proses memasukkan data yang telah ditransformasi ke dalam tabel tujuan (data warehouse atau datamart) agar siap digunakan untuk analisis.



STORED PROCEDURE

Stored Procedure

Stored procedure datamart dibuat untuk:

- Mengotomatisasi proses **refresh data datamart**
- Menghindari query manual berulang
- Menjamin data selalu **up-to-date**
- Mempercepat proses ETL (bagian Load)

Stored Procedure

Step - 1

```
▷Run | Select  
CREATE OR REPLACE PROCEDURE datamart.refresh_all_datamart()  
LANGUAGE plpgsql  
AS $$  
BEGIN
```

- Membuat procedure untuk mengotomatisasi proses refresh datamart
- Menggunakan schema **datamart**
- Ditulis dengan bahasa **plpgsql**

Penjelasan Code:

CREATE OR REPLACE PROCEDURE → Update procedure jika sudah ada

datamart → Schema tujuan

refresh_all_datamart → Merefresh datamart

Stored Procedure

Step - 2

```
-- Hapus data lama  
TRUNCATE TABLE datamart.dm_sales_per_hour;  
TRUNCATE TABLE datamart.dm_product_sales;  
TRUNCATE TABLE datamart.dm_store_sales;  
TRUNCATE TABLE datamart.dm_category_monthly;
```

Tahap ini bertujuan untuk membersihkan data lama secara cepat menggunakan **TRUNCATE TABLE**, sehingga proses load data baru tidak menyebabkan duplikasi.

Stored Procedure

Step - 3

Load Data → Datamart

Setelah proses pembersihan data dengan **TRUNCATE TABLE**, tahap berikutnya adalah melakukan proses loading data ke dalam table datamart yang telah disiapkan, berdasarkan hasil transformasi dari data warehouse.

Penjelasan Code:

DATE_TRUNC ('hour', ...) → Fungsi untuk mengelompokkan per jam

COUNT(DISTINCT f.transaction_number) → Total transaksi

COUNT(DISTINCT f.customer_id) → Jumlah customer

```
-- Insert ulang dm_sales_per_hour
INSERT INTO datamart.dm_sales_per_hour
SELECT
    DATE_TRUNC('hour', f.sales_date) AS hour,
    COUNT(DISTINCT f.transaction_number),
    COUNT(DISTINCT f.customer_id)
FROM dwh.fact_sales f
GROUP BY DATE_TRUNC('hour', f.sales_date);

-- Insert ulang dm_product_sales
INSERT INTO datamart.dm_product_sales
SELECT
    product_id,
    SUM(quantity)
FROM dwh.fact_sales
GROUP BY product_id;


-- Insert ulang dm_store_sales
INSERT INTO datamart.dm_store_sales
SELECT
    store_id,
    SUM(quantity)
FROM dwh.fact_sales
GROUP BY store_id;

-- Insert ulang dm_category_monthly
INSERT INTO datamart.dm_category_monthly
SELECT
    p.category_name,
    d.year,
    d.month,
    SUM(f.sales)
FROM dwh.fact_sales f
JOIN dwh.dim_product p ON f.product_id = p.product_id
JOIN dwh.dim_date d ON f.sales_date = d.date_id
GROUP BY p.category_name, d.year, d.month;
```



PARTITIONING

PARTITIONING



Partitioning adalah teknik membagi tabel besar menjadi beberapa bagian kecil (**partition**) berdasarkan kriteria tertentu, biasanya tanggal (**daily partitioning**).

Bagaimana Partitioning Meningkatkan Efisiensi Pengolahan Data ?

Query Lebih Cepat


Database hanya membaca partition yang relevan, tanpa partition, database akan membaca seluruh table.

Mengurangi Beban I/O

Data yang dibaca oleh sistem akan lebih sedikit maka berdampak ke disk access akan lebih ringan.

Proses ETL Lebih Cepat

Insert data hanya ke partition tertentu, tidak akan mengganggu data yang lama.



KESIMPULAN



KESIMPULAN



Proses ETL (Extract, Transform, Load) berhasil mengubah data transaksi mentah menjadi data yang terstruktur dan siap digunakan untuk analisis melalui penerapan **data warehouse, star schema, dan datamart**.

Manfaat ETL

- Data lebih terstruktur
- Meningkatkan performa query
- Mendukung analisis bisnis
- Automasi proses data
- Efisiensi